

宋柏君

多模态生成 · 世界模型 · 表征学习

19350669024 · b.song.echo@gmail.com · GitHub · Google Scholar

专注于多模态生成、世界模型、表征学习，具备从研究问题定义到模型设计再到大规模训练与评测的完整实践经验。



教育

清华大学 | 电子信息 | 硕士 | 袁春教授指导 2024.09 - 2027.06

大连理工大学 | 力学 | 本科 2020.09 - 2024.06

实习

美团 | 多模态算法科研实习生（校企合作） | 点评·智能创作团队 2025.07 - 至今

获评美团优秀科研实习生

WorldRoll: World Model Data & Post-Training

第一作者, AAAI 2027 Under Review | 2025.08 - 2026.07

- 独立设计并实现面向 I2V 世界模型的数据 pipeline，将相机位姿/轨迹等信号转化为仅依赖首帧 + 自然语言的 world rollout 数据，模型在训练或推理阶段可仅通过自然语言实现精确的相机控制。
- 构建三源数据 pipeline：融合带相机位姿真实视频、场景动态真实视频、教师世界模型（HY-WorldPlay）生成数据；完成基于 VLM（Qwen3.6-27B）的标注与筛选，得到 60K 高质量训练视频。
- 对 LTX-Video-2B 与 CogVideoX-Fun-2B 在该数据集上进行 LoRA 微调后，两者在 WorldScore Static 提升 8.1% / 8.8%，Dynamic 提升 5.5% / 5.9%，WorldModelBench 提升 5.2% / 4.9%；进行数据组合、数据/训练 scaling 等实验；目前在内部进一步面向大众点评商家垂域场景构建数据。

RibbonTok: Visual Tokenization for AR Generation

第一作者, AAAI 2027 Under Review | 2025.08 - 2026.07

- 独立设计并实现面向自回归图像生成的多分辨率、单流、可变长度 tokenizer，将图像编码为 coarse-to-fine 的 1D causal token sequence，其任意前缀序列均可独立被解码重建成多物理分辨率图像。
- 提出模型结构：causal masked-register ViT、stacked directional codebooks 与 flow DiT；提出训练方式 coalesce matching，显式约束跨分辨率视图的前缀表征，使逻辑图像表征与物理输出分辨率解耦。
- 训练三种规模（300M、1B、2.5B）的 tokenizer，后者在 ImageNet 上取得 rFID 1.04 @ 256 重建指标；训练两种规模（1B、3B）的 Llama-style AR 模型，后者在 ImageNet 上仅生成 32 tokens 即达到 gFID 1.43 / IS 348.8 的生成指标，超越同规模模型（如 LlamaGen-3B）的同时实现 >2x 端到端加速。

论文

1. WorldRoll: From Privileged Camera Trajectories to Pose-Free World Rollouts

第一作者, AAAI 2027 Under Review | 论文 PDF · 补充材料 PDF

2. RibbonTok: Multi-Resolution, Single-Stream, and Adaptive-Length Tokenization for Autoregressive Image Generation

第一作者, AAAI 2027 Under Review | 论文 PDF · 补充材料 PDF

3. M3Time: LLM-Enhanced Multi-Modal, Multi-Scale, and Multi-Frequency Multivariate Time Series Forecasting

共同第一作者, AAAI 2026 Poster | 论文 PDF

技能

- 模型：熟练掌握 PyTorch；熟悉 Transformers、Diffusers 等框架；实现过各种 DiT 结构，如类似 HunyuanVideo 的 MMDiT、类似 Wan 的 DiT；实现过各种位置编码，如类似 Qwen 的 MMRoPE；实现过多模态序列切分/聚合，如针对 MoE-FFN、SP 等场景；熟悉多种 Attention 变体，如 FlashAttention、SageAttention。
- 训练/推理：掌握 FSDP、USP (Ulysses + RingAttention)、Gradient Checkpointing 等训练技巧；熟悉 PyTorch Distributed、Accelerate、DeepSpeed 等训练框架，实操过 HunyuanVideo (8B) 在 241 帧 720p 视频上的多机 (2 × 8 A100) + FSDP + USP + Gradient Checkpointing 训练；熟悉 vLLM 等推理框架；掌握多模态/多对话的请求处理；熟悉 DiffSynth-Studio、VideoX-Fun 等第三方仓库。
- 数据：多模态数据下载、管理、清洗；数据生成、标注、筛选、分析等。
- 编程：掌握 Python、C++；熟悉 Swift、C#；了解 Triton、CUDA、Metal。
- 英语：TOEFL 106 (L30 / R29 / S24 / W23)，CET-6 624，CET-4 647。